

Modelos Fundacionales en IA Generativa

Definiciones, notación matemática, aplicaciones y su lectura desde la teoría de sistemas complejos

1 1. Definiciones centrales

Modelo Fundacional (Foundation Model)

Modelo entrenado sobre datos masivos y heterogéneos mediante aprendizaje auto-supervisado a gran escala, que aprende representaciones generales f_θ transferibles a un amplio rango de tareas posteriores (*downstream*) mediante adaptación (*fine-tuning*, *prompting* o *in-context learning*), sin requerir reentrenamiento desde cero.

Propiedades definitorias:

- **Homogeneización:** una sola arquitectura base sirve como sustrato para múltiples tareas.
- **Emergencia:** capacidades no explícitamente programadas que surgen al aumentar escala.
- **Transferencia:** el conocimiento pre-entrenado se reutiliza mediante adaptación de bajo costo.

Auto-supervisión. El modelo genera su propia señal de entrenamiento a partir de los datos, sin etiquetas humanas: en texto, predecir el siguiente token; en visión, reconstruir regiones enmascaradas.

2 2. Funcionamiento principal

La mayoría de los modelos fundacionales actuales (GPT, LLaMA, Gemini, CLIP) se basan en la arquitectura **Transformer**, cuyo componente central es la *atención*.

Mecanismo de auto-atención: dados los vectores de consulta Q , llave K y valor V (proyecciones lineales de la entrada X):

$$\text{Atención}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V \quad (1)$$


donde d_k es la dimensión de las llaves; el escalado $1/\sqrt{d_k}$ estabiliza el gradiente al evitar saturación del softmax.

Atención multi-cabeza:

$$\begin{aligned} \text{MHA}(X) &= \text{Concat}(h_1, \dots, h_n) W^O \\ h_i &= \text{Atención}(XW_i^Q, XW_i^K, XW_i^V) \end{aligned} \quad (2)$$

Cada bloque Transformer combina MHA con una red *feed-forward* y conexiones residuales con normalización:

$$\begin{aligned} z &= \text{LayerNorm}(x + \text{MHA}(x)) \\ y &= \text{LayerNorm}(z + \text{FFN}(z)) \end{aligned} \quad (3)$$



figureBloque Transformer apilado ($\times N$); líneas punteadas: conexiones residuales.

Función de pérdida

Para modelos de lenguaje, la pérdida estándar es la **entropía cruzada** sobre la predicción autoregresiva del siguiente token:

$$\mathcal{L}(\theta) = - \sum_{i=1}^T \log P_\theta(x_i | x_{<i}) \quad (4)$$

Minimizar $\mathcal{L}$ equivale a maximizar la verosimilitud de los datos de entrenamiento bajo el modelo.

Optimización


Los parámetros θ (miles de millones) se ajustan por **descenso de gradiente estocástico** adaptativo (Adam/AdamW):

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}} \quad (5)$$

donde $\hat{m}_t, \hat{v}_t$ son estimaciones de primer y segundo momento del gradiente $\nabla_\theta \mathcal{L}$, y η es la tasa de aprendizaje. El costo computacional total sigue leyes de escalamiento empíricas:

$$L(C) \approx a C^{-\alpha} + L_\infty \quad (6)$$

con C el cómputo de entrenamiento (FLOPs) y α un exponente empírico $\approx 0.05-0.1$ (Kaplan et al., 2020).



3 3. Aplicaciones concretas

Generación de lenguaje natural

Modelo: GPT / LLaMA (decodificador Transformer autoregresivo).

Ejemplo concreto: un asistente conversacional que resume un contrato legal de 40 páginas en un párrafo, generando cada token x_i a partir de $P_\theta(x_i | x_{<i})$.

Visión-lenguaje

Modelo: CLIP (aprendizaje contrastivo imagen-texto).

Ejemplo concreto: búsqueda de fotos por descripción textual (“factura con sello borroso”) mediante similitud coseno entre *embeddings* de imagen y texto en un espacio compartido.

Generación de imágenes

Modelo: modelos de difusión (Stable Diffusion, DALL·E) que invierten un proceso de ruido gaussiano $x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon$.

Ejemplo concreto: generar el boceto de un diagrama arquitectónico a partir de una descripción escrita.

Detección de anomalías / fraude

Modelo: *embeddings* fundacionales de series tabulares o texto combinados con un detector no supervisado (p. ej. Isolation Forest) sobre el espacio latente $f_\theta(x)$.


Ejemplo concreto: un reclamo de seguro atípico se aleja del centroide de comportamiento “normal” aprendido durante el pre-entrenamiento, elevando su puntaje de anomalía.

4 4. Lectura desde sistemas complejos

Un modelo fundacional puede entenderse como un **sistema complejo adaptativo**: miles de millones de parámetros (agentes locales) interactúan mediante reglas simples (multiplicación de matrices, atención) y producen comportamiento global no reducible a sus componentes.

Emergencia y transición de fase

La **emergencia** —concepto central de la teoría de sistemas complejos— describe capacidades (razonamiento aritmético, traducción *zero-shot*) ausentes en modelos pequeños que aparecen abruptamente al superar un umbral de escala C^* , de forma análoga a una **transición de fase** en física estadística: el sistema exhibe un cambio cualitativo discontinuo pese a que el “ajuste de parámetros” subyacente es continuo.



Auto-organización

Durante el entrenamiento, las representaciones internas se auto-organizan en jerarquías de abstracción (sintaxis → semántica → razonamiento) sin que ninguna capa reciba instrucción explícita de organizarse así, un ejemplo directo de **auto-organización** de sistemas alejados del equilibrio.

No linealidad y sensibilidad


La superficie de pérdida $\mathcal{L}(\theta)$ es altamente no convexa; pequeñas variaciones en *prompt*, temperatura de muestreo o *seed* pueden producir salidas cualitativamente distintas —análogo funcional a la **dependencia sensible a condiciones iniciales** de sistemas caóticos, aunque acotada por la naturaleza estocástica controlada del muestreo:

$$x_i \sim P_\theta(\cdot | x_{<i}), \quad P_\theta \propto \exp\left(\frac{z_i}{T}\right) \quad (7)$$

con T la temperatura: $T \rightarrow 0$ colapsa el sistema a un atractor determinista (decodificación voraz); T alto amplía el espacio de trayectorias posibles, análogo al control de un parámetro de bifurcación.

Redes de interacción

La atención entre *tokens* define, en cada paso, un **grafo dirigido y ponderado** de interacción (matriz $QK^\top$), cuya topología cambia dinámicamente por capa y por entrada —un caso concreto de red compleja adaptativa evolucionando en tiempo de inferencia.



figureGrafo de atención entre tokens $t_1, \dots, t_5$: red ponderada dinámica.

5 5. Síntesis

Los modelos fundacionales combinan tres pilares matemáticos —**arquitectura** (atención Transformer), **función objetivo** (entropía cruzada) y **optimización** (descenso de gradiente adaptativo a escala masiva)— cuyo comportamiento agregado no se explica solo por la suma de sus partes. Sus leyes de escalamiento, capacidades emergentes y sensibilidad a condiciones iniciales los sitúan como un objeto de estudio legítimo para la teoría de sistemas complejos y la cibernética, más allá de su lectura puramente estadística.

Referencias clave: Bommasani et al. (2021), *On the Opportunities and Risks of Foundation Models*; Vaswani et al. (2017), *Attention is All You Need*; Kaplan et al. (2020), *Scaling Laws for Neural Language Models*; Wei et al. (2022), *Emergent Abilities of Large Language Models*.